·特约综述·

“人工智能与生物医学”专题

AlphaFold时代的蛋白质相关人工智能算法及其应用*

孙雨楠[1,2,#]，叶　川[1,2,#]，赵东宇[1,2,△]

([1]北京大学基础医学院医学生物信息学系，北京 100191；[2]北京大学血管稳态与重构全国重点实验室，北京 100191)

摘要　蛋白质是生命活动的物质基础。蛋白质的功能取决于其空间结构，因此解析蛋白质的空间结构对于理解其功能至关重要。人工智能(artificial intelligence，AI)模型的利用极大地推进了蛋白质空间结构预测算法的开发，AlphaFold2是该领域里程碑式的成果，使得快速、准确且大规模的蛋白质空间结构预测成为可能。此外，蛋白质语言模型、蛋白质相互作用预测以及蛋白质设计等领域均在AlphaFold时代迎来快速发展，代表性的模型包括ESM2、ScanNet、RFdiffusion和RoseTTAFold-All Atom等。这些基于人工智能的新算法的开发极大地促进了蛋白质功能、诱发疾病的机制和药物设计等领域的研究。

关键词　蛋白质结构预测；AlphaFold2；蛋白质语言模型；蛋白质相互作用预测；蛋白质设计

中图分类号　Q811.4

Protein-Related Artificial Intelligence Algorithms and Their Applications in the AlphaFold Era*

SUN Yu-Nan[1,2,#], YE Chuan[1,2,#], ZHAO Dong-Yu[1,2,△] ([1]*Department of Biomedical Informatics, School of Basic Medical Sciences, Peking University*, Beijing 100191, China; [2]*State Key Laboratory of Vascular Homeostasis and Remodeling, Peking University*, Beijing 100191, China)

Abstract　Proteins serve as the fundamental building blocks of life processes. Their functions are highly determined by the spatial structure, making analyzing these spatial structures essential for fully comprehending their roles. The application of artificial intelligence (AI) models has significantly advanced the development of algorithms for predicting protein spatial structure. AlphaFold2 represents a groundbreaking advancement in this field, enabling rapid, accurate, and large-scale predictions of protein spatial structures. In the AlphaFold era, substantial progress has been made in fields such as protein language model development, protein-protein interaction

引用格式：孙雨楠，叶川，赵东宇. AlphaFold时代的蛋白质相关人工智能算法及其应用. 生理科学进展. 2025，56(3)：202～209.

SUN Yu-Nan, YE Chuan, ZHAO Dong-Yu. Protein-related artificial intelligence algorithms and their applications in the AlphaFold era. Progress in Physiological Sciences. 2025, 56(3): 202～209. DOI: 10.20059/j.cnki.pps.2025.02.1006

收稿日期：2025-01-03；修回日期：2025-02-01；接受日期：2025-02-01

* 国家自然科学基金面上项目(32270603)；北京市自然科学基金面上项目(5242010)资助课题

等同贡献

△ 通信作者　zhaodongyu@bjmu.edu.cn

prediction, and protein design, with notable models including ESM2, ScanNet, RFdiffusion, and RoseTTAFold-All Atom, among others. These novel AI-based algorithms have profoundly facilitated research into protein function, disease mechanisms, and drug design.

Key words protein structure prediction; AlphaFold2; protein language model; protein interaction prediction; protein design

蛋白质结构预测是生物领域重要的科学问题，也是困扰研究人员半个多世纪的难题。传统的蛋白质结构预测算法主要基于已知结构的蛋白质比对以及物理学先验知识，其预测精度较低，与实验测定的数据相差较大，该方向的发展曾遭遇瓶颈，而其突破来自于人工智能技术的引入。AlphaFold2 是人工智能模型，基于大量已知的蛋白质空间结构数据进行训练，从而具有准确且高效的蛋白质空间结构预测能力[1]。随后，针对蛋白质相互作用预测、蛋白质设计和蛋白质功能预测等任务的人工智能模型快速涌现，将蛋白质研究带入全新的人工智能时代。

一、蛋白质空间结构预测

蛋白质是由氨基酸残基经肽键连接所形成的肽链折叠而成。其特定的空间结构与其功能密切相关。利用 X 射线晶体学、核磁共振和冷冻电镜等技术可以精确地解析蛋白质结构，但实验方法耗时、昂贵且技术复杂，难以对蛋白质结构进行批量解析[2]。因此，非实验依赖的蛋白质结构解析方法是几十年来众多科学家们所深耕的领域。

早在 1973 年，诺贝尔化学奖得主 Christian B. Anfinsen 即提出了“对于一个在标准生理环境下的小球状蛋白质来说，其天然结构仅由蛋白质的氨基酸序列决定”[3]，该观点被称为 Anfinsen 法则，奠定了通过蛋白质的氨基酸序列预测蛋白质空间结构的基础。

蛋白质的结构预测算法可以分为基于模板的建模(template-based modeling, TBM)以及从头预测方法(ab initio prediction)。TBM 方法可以进一步分为同源建模和穿线法[4]。同源建模方法是根据已知空间结构的同源蛋白质来预测目标蛋白质空间结构的常用方法。它的基本原理是基于序列相似性，假设具有高度相似氨基酸序列的蛋白质通常会折叠成相似的三维结构[5]。1969 年，Browne 等[6]提出的首个蛋白质结构预测算法就是基于同源建模策略。与同源建模法关注序列相似性不同，穿线法假设不相似的氨基酸序列也可以折叠为相似的蛋白质空间结构。该方法从蛋白质结构数据库中识别与待测序列具有相似折叠类型的蛋白质，进而实现对待测序列的空间结构预测。1991 年，Bowie 等[7]开发了蛋白质反向折叠方法，该方法用于寻找能够折叠成已知空间结构的氨基酸序列，并广泛应用于后续的穿线法结构预测以及蛋白质设计。蛋白质空间结构从头预测方法不依赖蛋白质模板，仅从氨基酸序列信息获得蛋白质空间结构的预测。该方法基于热力学的自由能最小化原理，认为蛋白质的稳定天然结构是其氨基酸序列折叠的自由能最低状态。该方法的关键在于如何定义氨基酸序列折叠的能量函数，以及如何最小化能量函数从而完成蛋白质结构的预测[8]。2004 年，David Baker 实验室[9]开发了蛋白结构从头预测方法 Rosetta。Rosetta 算法将目标蛋白的氨基酸序列分解为短片段，并从蛋白质结构数据库(protein data bank, PDB)[10]中提取这些片段。这些片段代表了已知蛋白质中局部结构的最佳折叠方式。随后，通过蒙特卡洛搜索策略，对片段进行反复的替换与组装。根据能量函数计算，寻找自由能最低的片段组合。

近年来，随着深度学习领域的迅速发展，蛋白质结构预测领域也迎来了新的研究范式。利用数据库中已知的蛋白质结构数据来训练深度学习模型，研究者得以开发出能够直接从氨基酸序列预测蛋白质结构的模型。

2017 年，谷歌团队 Vaswani 等[11]提出了 Transformer 深度学习架构。虽然 Transformer 最初是为了解决自然语言处理(natural language processing，NLP)任务而设计的，但它不仅在 NLP 领域引发了革命性变化，还被广泛应用于计算机视觉和多模态模型等领域，成为深度学习领域的里程碑式成果。在 Transformer 架构提出之前，递归神经网络(recurrent neural network，RNN)及其变种，如长短期记忆网络(long short-term memory，LSTM)和门控循环单元(gated recurrent unit，GRU)，是处理序列数据的主流方法[12]。然而，这些模型在处理长序列，并捕捉序列中远距离依赖关系时会存在困难。Transformer 模型引入了自注意力机制，使模型在每一步处理时可以通过可训练的权重同时关注序列中的所有其他元素，从而有效解决了之前模型

在长依赖问题上的局限性。凭借自注意力机制的优势,Transformer在表示文本、语音等序列数据方面实现了质的飞跃,并且在处理DNA序列、蛋白质氨基酸序列中也展现出了卓越的性能[13]。

2021年,谷歌团队Jumper等[1]开发的AlphaFold2与David Baker实验室[14]开发的RoseTTAFold在几乎相同的时间分别于Nature和Science发表。二者均是基于Transformer构建的端到端蛋白质结构预测模型,可以从蛋白质序列的输入开始,经过复杂的网络架构,直接生成三维结构的原子坐标。在模型的训练过程中,无需中间步骤的独立优化或人工干预,模型参数通过从输入序列到最终三维坐标的误差反向传播进行联合优化。AlphaFold2将输入的氨基酸序列进行双轨编码,其一是输入序列在数据库中进行多序列比对(multiple sequence alignment, MSA)后形成的MSA表示矩阵,其二是对蛋白质序列中每对氨基酸残基之间的相互关系进行编码的成对表示矩阵。这两个矩阵共同输入Evoformer模块:MSA矩阵分别按行与按列进行Transformer编码,从而学习氨基酸序列中的远程相互作用;随后与成对表示矩阵联合,进入三角不等式模块,使模型捕捉蛋白质结构中残基之间的几何约束。Evoformer模块共串联48次,从而对氨基酸序列进行充分的编码,使得两个矩阵能够更加准确地表征特征信息。最后,两个矩阵进入8次串联的结构预测模块,利用SE(3)-Transformer[15]处理三维原子坐标信息,在多次迭代优化后生成蛋白质的三维原子坐标。Evoformer模块与结构预测模块共同进行三次循环,通过多次信息传递和逐步优化,不断细化模型对蛋白质序列和残基之间相互作用的理解,最终生成更精确的三维结构预测。AlphaFold2预测的蛋白质结构与实验解析结构的均方根误差在1埃左右,达到了原子级精度的预测。RoseTTAFold在类似的双轨编码的基础上,加入了第三轨道的信息,即使用SE(3)-Transformer[15]直接编码结构信息。结构编码轨道结合了来自MSA表示矩阵与成对表示矩阵的相互作用信息,不断优化调整氨基酸残基的空间排布,实现高精度的蛋白质结构预测。2024年,Jumper团队[16]成功研发了AlphaFold3并发表于Nature,该模型在AlphaFold2的基础上改进了模型结构并引入diffusion模块,进一步推动了蛋白质结构预测领域的发展。此外,研究人员利用AlphaFold2预测了超过两亿蛋白质的结构,并构建了AlphaFold蛋白质结构数据库[17]。

蛋白质结构预测算法以及数据库的快速发展将极大地促进蛋白质的生物学功能、药物靶点发现和疾病机制等领域的研究,蛋白质研究由此进入了AlphaFold时代。鉴于AlphaFold2对于生物医学研究的巨大影响,其开发者也于2024年获得诺贝尔化学奖。

二、蛋白质语言模型及其应用

AlphaFold2的计算流程高度依赖于通过数据库搜索目标序列所获得的MSA。若目标序列缺乏足够的同源序列,导致难以生成高质量的MSA,那么AlphaFold2的预测准确性将显著降低。此外,MSA还是AlphaFold2计算流程中最耗时的步骤,尤其是在需要预测数千万甚至上亿个序列时,这一过程不仅耗时长,而且对计算资源的消耗也非常巨大。为了解决这一问题,蛋白质语言模型(protein language model, PLM)应运而生,其中最具代表性的工作是Lin等[18]开发的ESM2模型。

ESM2模型同样基于Transformer架构,采用掩码的方式进行自监督训练,即随机掩盖氨基酸序列中15%的氨基酸残基,模型需根据序列的上下文填补这些空缺。经过UniRef数据库中约6500万条氨基酸序列的训练,ESM2模型学习到氨基酸残基间的相互依赖关系。此外,作者通过评价ESM2模型预测氨基酸残基间长程接触的准确率,发现ESM2模型虽然只经过氨基酸序列的训练,却能够学习到蛋白质结构的信息,这也一定意义上验证了Anfinsen法则。ESM2蛋白质语言模型在连接AlphaFold2模型的Evoformer模块和结构预测模块之后,构成ESMFold模型[18],可用于蛋白质结构的预测。ESMFold在蛋白质结构预测的准确性上略逊于AlphaFold2模型,然而由于ESMFold无需MSA步骤,其运行速度比AlphaFold2快6~60倍。若剔除AlphaFold2的MSA步骤,其预测准确性显著低于ESMFold。因此,对于没有高质量的MSA的目标序列,ESMFold在结构预测中可能更有优势。得益于ESMFold的高效计算能力,大规模蛋白质结构预测得以实现。在该工作中,作者运用ESMFold对来自6亿宏基因组测序数据的序列进行了蛋白质空间结构的预测,并揭示出其中2.6%的蛋白质属于全新类别,这些蛋白质在现有数据库中既找不到序列同源的蛋白质,也缺乏结构相似的蛋白质。

蛋白质语言模型的应用不仅限于蛋白质结构预

测。通过将氨基酸序列输入 ESM2 模型,ESM2 能够生成该序列的向量表示,这种表示虽然抽象且令人难以直接理解,却高度浓缩了蛋白质的序列和结构信息。在这种情况下,ESM2 模型充当了特征提取器,其提取的特征输入到下游模型中,可以显著提升下游模型的表现。自 ESM2 于 2022 年发布以来,许多研究基于 ESM2 展开,蛋白质功能预测、亚细胞定位预测等模型均获益于 ESM2 的特征提取能力[19]。Mall 等[20]基于 ESM2 模型开发了蛋白质毒性预测工具 VISH-Pred。该模型采用两种策略利用 ESM2 模型:其一,使用 ESM2 的架构,对于蛋白质毒性预测任务进行重新训练,从而获得端到端的预测模型;其二,将 ESM2 模型输出的氨基酸序列的向量表示,作为传统机器学习模型 XGBoost[21]或 LightGBM[22]的输入,从而对蛋白质毒性进行预测。Luo 等[23]对 ESM2 模型对氨基酸序列表示的可解释性进行了深入挖掘,他们将 ESM2 模型的最后一个隐藏层的信息进行提取,从而使得氨基酸序列的表示与生物学意义相关联。他们利用该策略实现了高准确度的蛋白质亚细胞定位预测。此外,ESM2 模型还被用于信号肽识别、蛋白质相似性检索等方面[24,25]。

ESM2 模型仅基于氨基酸序列进行训练,虽然可以学习到序列中蕴含的蛋白质结构信息,但是单一的序列信息仍然限制了模型能力的进一步提高。为了解决这一问题,许多在训练中纳入更多信息的蛋白质语言模型被开发。Hayes 等[26]发布的 ESM3 模型在训练时将序列信息、结构信息以及蛋白质功能信息进行联合输入,多模态信息的融合使得 ESM3 模型的隐空间具有更强的蛋白质表征能力。该模型具有序列、结构和功能之间联合推理的能力,输入有缺失的部分蛋白质信息,模型可输出所有模态的预测。Wang 等[27]开发的 S-PLM 蛋白语言模型使用 Swin-Transformer[28]对 AlphaFold2 预测的蛋白质结构进行编码,并与 ESM2 编码的序列信息进行融合,经过对比学习训练,模型获得了对于蛋白质序列与蛋白质结构进行共同编码的能力。该模型可用于多种下游的蛋白质预测任务,包括蛋白质分类、聚类等任务。Lin 等[29]开发的 ProTokens 模型分别将蛋白质的骨架结构信息以及氨基酸侧链的结构信息输入向量量化变分自编码器(vector quantized variational autoencoder, VQVAE)[30],从而获得包含结构信息的 VQVAE 隐空间的离散化表示,该表示经过生成式模型还原蛋白质空间结构。该模型可以将蛋白质的结构信息高度浓缩为向量表示,从而用于各类下游的蛋白质预测任务。

蛋白质语言模型仍在快速发展中,未来的方向将集中在对蛋白质序列和结构信息的更精细化表示,以及利用模型输出的蛋白质表示(protein representations)来支持多样化的下游任务。

三、蛋白质相互作用预测

蛋白质相互作用包括蛋白质-蛋白质相互作用(protein-protein interactions, PPIs)、蛋白质-核酸相互作用、蛋白质-配体相互作用等类型,在细胞的各种生理和生命活动过程中具有重要作用,构成了细胞信号传导和代谢调控等生物过程的基础[31]。对蛋白质相互作用的预测是计算生物学学科一个重要的科学问题,在生理学、药理学、药物开发、分子治疗等方面具有重要的理论意义和应用价值。蛋白质相互作用预测的目标主要包含结合位点预测和亲和力预测。

有很多学者在蛋白质结合位点预测方面做出了有价值的工作。2022 年 Haim J. Wolfson 实验室[32]提出了新型几何深度学习模型 ScanNet 用于预测蛋白质与小分子、其他蛋白质以及抗体的结合位点。该模型直接从三维结构中提取特征,并结合了原子层面和氨基酸层面的信息,利用模型来整合多个尺度信息以提高准确度。该模型不仅能运用于蛋白质-蛋白质相互作用预测,还可用于抗体结合位点预测。作者探索将其运用于 SARS-CoV-2 的刺突蛋白上,验证了已有的抗原位点并预测了新的位点。G 蛋白偶联受体(G protein-coupled receptor, GPCR)的结合位点预测一直是一个热点问题,GPCR 作为一类重要的受体家族,具有超过 800 个成员,且超过三分之一的 FDA 批准药物的靶点是 GPCR[33],因此如何实现受体结合位点的预测和受体脱孤(寻找并鉴定孤儿受体的内源性配体的过程)是一个重要的科学问题。国内的学者提出了一种名为 DeepGlycanSite 的方法[34],关注糖类分子和 GPCR 相互作用的结合位点预测。糖类分子参与调节包括免疫、细胞分化、代谢等诸多生物过程,理解其结合位点和相互作用对于药物开发至关重要。学者们通过特征提取、图神经网络和 Transformer 构建了一个预测模型来预测糖分子结合受体的结合位点,该模型的提出可以为具有治疗意义的受体脱孤和药物开发提供新的见解。最近的研究对于蛋白质-核酸结合位点预测问题提出了 EquiPNAS 模型,模型对蛋白质单体进行预处理,特征提取方面包括

ESM2 模型生成的蛋白质特征表示[18],以及残基类型、位置特异性评分矩阵和多序列比对等其他特征,将其预处理为图表征,而后通过 E(3)等变图神经网络架构对图表征进行学习,使用图节点分类来实现残基水平的结合位点预测,该模型或可用于进一步开发准确的、稳健的、可拓展的计算方法来模拟蛋白质-核酸复合物结构[35]。2024 年发表的 AlphaFold3[16]可以预测蛋白质-蛋白质以及蛋白质-小分子的复合物结构,对蛋白质相互作用结构预测有了突破性的变革。该模型不仅将多种不同的任务集成于一体,其预测效果和广度更是远超之前的预测模型,该模型从计算生物学的角度上推动了蛋白质的研究。这些模型的开发可以加速开发新材料、新药物,并且可以更深入地理解蛋白质-核酸、蛋白质-蛋白质相互作用,为材料学、药理学、基因组学研究提供新的见解。

如何快速准确预测蛋白质-配体结合亲和力是另一重要的科学问题。配体种类繁多,性质复杂,因此亲和力预测的难度较大,是药物开发中的一个重大的挑战。现有方法主要通过蛋白质口袋、配体以及二者的相互作用进行特征提取,而后使用深度学习方法进行处理,最终输出亲和力。一种名为 CAPLA(cross-attention for protein-ligand binding affinity)的方法就是个典型的例子,该方法不仅通过输入传统的蛋白质和配体的表示来提取特征,还通过交叉自注意力机制捕获蛋白质结合口袋和配体之间的相互影响,最终使用神经网络预测蛋白质-配体结合亲和力[36]。另一个用于化合物-蛋白质结合亲和力预测的 StackCPA 模型[37]近年被提出,模型通过迁移学习策略整合了包括蛋白质口袋和化合物的多尺度特征,以细粒度的方式从原子(atom)水平、残基(residue)水平和结构子区域(subdomain)水平对蛋白质口袋进行了细致的描述,将预处理后的数据输入到由三部分(模块)组成的神经网络之中,不同部分使用了不同的回归模型,以适用于预测亲和力。近年学者们还发表了很多基于机器学习或深度学习的模型,包括 DeepDTAF[38]、PBCNet[39]等,这些模型使用不同的输入,包括小分子配体、蛋白质序列和蛋白质结构等信息中的一种或几种,而后进行特征提取处理后嵌入到神经网络中并对亲和力进行预测。比较特别的模型是 ProBound[40],该模型能够从大规模测序数据中预测蛋白质-配体亲和力,其优势在于能够学习生物物理上的特征,具有一定的可解释性,为解码生物网络和合理设计蛋白质-配体相互作用提供了新的途径。

通过 AI 理解蛋白质与其他物质的相互作用于多种层面上具有深远的意义,这不仅有助于解码细胞功能及其调控的分子机制、揭示疾病发生发展的机理、促进药物的开发,还在合成生物学领域展现出巨大的应用潜力。AI 算法在预测蛋白质相互作用方面的应用广泛,这些算法能够从计算生物学的角度进行评估和筛选,从而缩小实验规模、提高筛选效率,AI 技术正是通过这种方式成为推动生物医学研究和药物开发的强大工具。

四、人工智能辅助蛋白质设计

蛋白质是生命活动的承担者,其理性设计和功能改造一直是一个重要的科学问题。蛋白质设计主要有两个方面,其一为蛋白质结构设计,其二为蛋白质的序列设计和优化。Christian. B. Anfinsen[3]根据核糖核酸酶折叠和重新折叠实验的结果,回答了一个重要的科学问题:蛋白质的一级结构可以决定蛋白质的空间结构,即序列决定结构。正是这样的结论为蛋白质序列和结构设计提供了理论基础。近年来计算机科学的大力发展,很大意义上促进了计算生物学的发展。

基于蛋白质结构进行从头设计和重新设计是蛋白质设计的重要路线。2024 年诺贝尔化学奖获得者之一的 David Baker 主要从事蛋白质的从头设计,使用不同方法设计出了感应小分子结合蛋白[41]、超稳定约束肽[42]和免疫细胞因子类似物[43]等非天然蛋白质。David Baker 实验室不仅使用生物学先验知识进行蛋白质设计,也关注于开发模型来辅助设计,该实验室开发了对标 AlphaFold2 的蛋白质预测工具 RoseTTAFold[14],且后来在此基础上加入了扩散模型(diffusion model)[44,45],开发出了 RFdiffusion[46],用于从头生成蛋白质骨架。具体而言,该方法通过在蛋白质结构去噪任务的基础上调整了 RoseTTAFold 预测网络,在其后接入了扩散模型,可以在无条件和无拓扑约束下完成蛋白质单体、对称寡聚体以及酶活性位点支架等方面设计工作。近年,David Baker 实验室使用 RFdiffusion 设计了包括胰高血糖素、甲状旁腺激素等激素的结合物(binders),这些激素在人体中具有重要的生理作用,目前对它们的敏感性和特异性定量一般依赖于抗体,而抗体存在造价高、资源消耗高、亲和力低等问题,因此学者们提出了一条新的人工智能辅助设计的路线,可以通过 RFdiffusion 设计高亲和力和高特异性的结合物来应用于生物传感器,具

有潜在的临床应用价值[47]。2024 年 RoseTTAFold All-Atom 被提出,该模型是一种新的基于深度学习的工具,能够从头设计并预测包含蛋白质、核酸、小分子、金属离子等组分的复合结构[48]。该方法将输入的一维序列信息、二维配对距离信息和三维坐标信息通过多个隐藏层迭代优化预测结构,并能在无专业知识的情况下从头设计蛋白质,在设计小分子结合蛋白和传感器方面有广泛应用前景。国内学者于 2022 年也提出了一种基于神经网络的 SCUBA 方法,该方法利用蛋白质设计的能量函数从头进行蛋白质设计。该工作设计了九种高精度的蛋白质,其中四种具有自然界中未发现的新颖结构[49]。这些设计在药物传递系统、合成生物学及分子疗法的构建方面具有重要的潜在应用价值,这些从头设计的蛋白质不同于天然的结构,具有创新性,可以为蛋白质工程和生物医学研究提供新的工具和策略。

蛋白质的序列设计和优化也是蛋白质设计和改造的一个重要方面。David Baker 实验室开发了 ProteinMPNN[50],一个根据蛋白质结构还原序列的工具,其序列恢复率高于原始的 Rosetta 方法,该工具也可进行序列的优化和设计,由于其广泛的适用性和计算效率,该模型不仅从理论上推动了深度学习在蛋白质设计的应用,更具有实际的转化意义,在新药开发和蛋白质优化方面有巨大的潜力。2024 年,来自北卡罗来纳大学医学院的学者们开发了一种基于深度学习方法的 ThermoMPNN[51],该模型主要包括两个模块,其一为预训练的 ProteinMPNN 模块,作者使用这个模块进行特征提取,再将其输入到第二个稳定性预测模块之中,提高了蛋白质稳定性变化预测的准确性和效率,对于蛋白质工程和药物开发具有潜在价值。Bruno E. Correia 等学者[52]通过 AF2seq[53]进行优化,通过选择可溶性蛋白质数据库对原有 ProteinMPNN 进行了重新训练,对优化后的序列进行再设计,得到了多种不同的可溶解结构类似物,包括 β 桶(β-barrel)折叠、紧密连接蛋白(claudin)折叠、GPCR 折叠等类似物的设计,该方法展示了通过深度学习流程可进行从头设计复杂且具有功能蛋白质结构的能力,提供了一种新的方法来优化现有靶点和配体,从而可能加速新药的开发。

AI 在辅助蛋白质设计领域的应用对于合成生物学的进步有重要的影响。其核心价值不仅在于提高了设计效率,而且通过理性设计使设计过程具有一定可解释性,这种可解释性对于科学家们深入理解蛋白质结构和功能是至关重要的,同时为蛋白质的定向改造和功能优化提供了可及的工具。通过理性设计并预测蛋白质的生物活性,研究人员可以设计出特定功能的蛋白质,这不仅加速了药物发现过程,缩短了成药周期,还提高了药物的有效性和创新性,避免了潜在的专利竞争问题。并且 AI 辅助蛋白质设计也在个性化医疗和精准医疗方面表现出了潜质,或可基于特定靶点开发对应的靶向药。

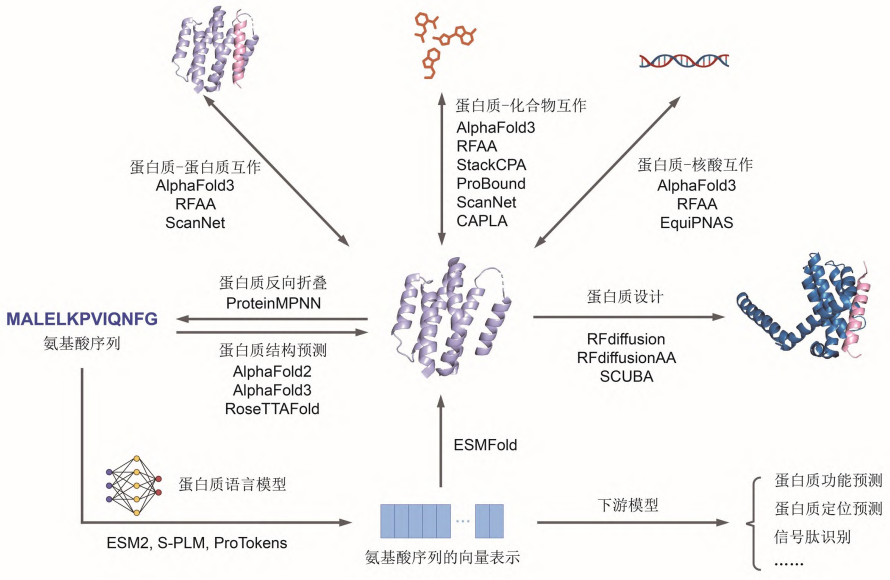


图 1 蛋白质相关人工智能算法

RFAA:RoseTTAFold All-Atom。蛋白质结构示例来源:PDB-ID: 3FDL[54];PDB-ID: 8T5E[47]

五、结语与展望

人工智能算法能够为蛋白质相关领域的研究赋能。不论是蛋白质结构预测、蛋白质相互作用、抑或是蛋白质的设计，都将从这些新兴的工具中获益，这些方法的应用可以对生理状态下的机体调控机制研究、疾病发生发展机制研究、药物研发、材料研发等方面有着深远且长期的影响。尤其是人工智能工具可以从大量样本中进行学习，正是这种机制能够适应大数据时代的数据量，从海量数据中挖掘出人类智能无法挖掘出的信息。在参数数量和模型规模提升到一定程度时，模型的性能和泛化能力会有一种显著提升的现象，该现象可称为涌现现象，这种现象具有巨大的应用前景和挖掘潜力，或可进一步指导科学发现和科学研究。然而，值得我们高度关注的是，由于生成式模型具有幻觉(hallucination)现象，即模型可能会生成看似合理且具有逻辑性的结果，但实际上并不基于合理的科学假设和科学现象。因此，我们需要一种通过专业知识和实验进一步验证的策略来进行优化，在充分利用其创造性的前提下规避可能存在的风险和负面影响。随着计算机科学和数据科学的进一步发展，人工智能算法将更加广泛地应用于蛋白质研究领域，在理解蛋白质的结构、功能、分子机制，甚至进一步在合成生物学方向获得不断的新突破，有望在疾病诊断、临床治疗等领域带来新的进展并提供新的研究范式。

参　考　文　献

1　Jumper J, Evans R, Pritzel A, et al. Highly accurate protein structure prediction with AlphaFold. Nature. 2021, 596: 583～589.

2　Dobson CM. Biophysical techniques in structural biology. Annu Rev Biochem. 2019, 88: 25～33.

3　Anfinsen CB. Principles that govern the folding of protein chains. Science. 1973, 181: 223～230.

4　Huang B, Kong L, Wang C, et al. Protein structure prediction: challenges, advances, and the shift of research paradigms. Genomics Proteomics Bioinformatics. 2023, 21: 913～925.

5　Soding J, Biegert A, Lupas AN. The HHpred interactive server for protein homology detection and structure prediction. Nucleic Acids Res. 2005, 33: W244～W248.

6　Browne WJ, North AC, Phillips DC, et al. A possible three-dimensional structure of bovine alpha-lactalbumin based on that of hen's egg-white lysozyme. J Mol Biol. 1969, 42: 65～86.

7　Bowie JU, Luthy R, Eisenberg D. A method to identify protein sequences that fold into a known three-dimensional structure. Science. 1991, 253: 164～170.

8　Bertoline LMF, Lima AN, Krieger JE, et al. Before and after AlphaFold2: An overview of protein structure prediction. Front Bioinform. 2023, 3: 1120370.

9　Rohl CA, Strauss CE, Misura KM, et al. Protein structure prediction using Rosetta. Methods Enzymol. 2004, 383: 66～93.

10　Berman HM, Westbrook J, Feng Z, et al. The protein data bank. Nucleic Acids Res. 2000, 28: 235～242.

11　Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need. Advances in Neural Information Processing Systems[C]. 2017, 30: 6000～6010.

12　Mao S, Sejdic E. A review of recurrent neural network-based methods in computational physiology. IEEE Trans Neural Netw Learn Syst. 2023, 34: 6983～7003.

13　Madan S, Lentzen M, Brandt J, et al. Transformer models in biomedicine. BMC Med Inform Decis Mak. 2024, 24: 214.

14　Baek M, DiMaio F, Anishchenko I, et al. Accurate prediction of protein structures and interactions using a three-track neural network. Science. 2021, 373: 871～876.

15　Fuchs FB, Worrall DE, Fischer V, et al. SE(3)-transformers: 3D roto-translation equivariant attention networks. arXiv. 2020.

16　Abramson J, Adler J, Dunger J, et al. Accurate structure prediction of biomolecular interactions with AlphaFold 3. Nature. 2024, 630: 493～500.

17　Varadi M, Anyango S, Deshpande M, et al. AlphaFold protein structure database: massively expanding the structural coverage of protein-sequence space with high-accuracy models. Nucleic Acids Res. 2022, 50: D439～D444.

18　Lin Z, Akin H, Rao R, et al. Evolutionary-scale prediction of atomic-level protein structure with a language model. Science. 2023, 379: 1123～1130.

19　Schmirler R, Heinzinger M, Rost B. Fine-tuning protein language models boosts predictions across diverse tasks. Nat Commun. 2024, 15: 7407.

20　Mall R, Singh A, Patel CN, et al. VISH-Pred: an ensemble of fine-tuned ESM models for protein toxicity prediction. Brief Bioinform. 2024, 25: bbae270.

21　Chen T, Guestrin C. XGBoost: A scalable tree boosting system. Knowledge Discovery and Data Mining [C]. 2016, 785～794.

22　Ke G, Meng Q, Finley T, et al. LightGBM: A highly efficient gradient boosting decision tree. Advances in Neural Information Processing Systems[C]. 2017, 30: 3149～3157.

23　Luo Z, Wang R, Sun Y, et al. Interpretable feature extraction and dimensionality reduction in ESM2 for protein localization prediction. Brief Bioinform. 2024, 25: bbad534.

24　Zeng S, Wang D, Jiang L, et al. Parameter-efficient

fine-tuning on large protein language models improves signal peptide prediction. Genome Res. 2024, 34: 1445～1454.
25 Iovino BG, Tang H, Ye Y. Protein domain embeddings for fast and accurate similarity search. Genome Res. 2024, 34: 1434～1444.
26 Hayes T, Rao R, Akin H, et al. Simulating 500 million years of evolution with a language model. bioRxiv. 2024.
27 Wang D, Pourmirzaei M, Abbas UL, et al. S-PLM: structure-aware protein language model via contrastive learning between sequence and structure. Adv Sci (Weinh). 2025, 12: e2404212.
28 Liu Z, Lin Y, Cao Y, et al. Swin transformer: hierarchical vision transformer using shifted windows. Proceedings of the IEEE/CVF International Conference on Computer Vision[C]. 2021, 10012～10022.
29 Lin X, Chen Z, Li Y, et al. Tokenizing foldable protein structures with machine-learned artificial amino-acid vocabulary. bioRxiv. 2023.
30 Oord AVD, Vinyals O, Kavukcuoglu K. Neural discrete representation learning. Advances in Neural Information Processing Systems[C]. 2017, 30: 6309～6318.
31 Liang S, Zhang C, Liu S, et al. Protein binding site prediction using an empirical scoring function. Nucleic Acids Res. 2006, 34: 3698～3707.
32 Tubiana J, Schneidman-Duhovny D, Wolfson HJ. ScanNet: an interpretable geometric deep learning model for structure-based protein binding site prediction. Nat Methods. 2022, 19: 730～739.
33 Rockman HA, Lefkowitz RJ. G protein-coupled receptors: from radioligand binding to cellular signaling. J Clin Invest. 2024, 134: e178109.
34 He X, Zhao L, Tian Y, et al. Highly accurate carbohydrate-binding site prediction with DeepGlycanSite. Nat Commun. 2024, 15: 5163.
35 Roche R, Moussad B, Shuvo MH, et al. EquiPNAS: improved protein-nucleic acid binding site prediction using protein-language-model-informed equivariant deep graph neural networks. Nucleic Acids Res. 2024, 52: e27.
36 Jin Z, Wu T, Chen T, et al. CAPLA: improved prediction of protein-ligand binding affinity by a deep learning approach based on a cross-attention mechanism. Bioinformatics. 2023, 39: btad049.
37 Lei C, Lu Z, Wang M, et al. StackCPA: A stacking model for compound-protein binding affinity prediction based on pocket multi-scale features. Comput Biol Med. 2023, 164: 107131.
38 Wang K, Zhou R, Li Y, et al. DeepDTAF: a deep learning method to predict protein-ligand binding affinity. Brief Bioinform. 2021, 22: bbab072.
39 Yu J, Li Z, Chen G, et al. Computing the relative binding affinity of ligands based on a pairwise binding comparison network. Nat Comput Sci. 2023, 3: 860～872.
40 Rube HT, Rastogi C, Feng S, et al. Prediction of protein-ligand binding affinity from sequencing data with interpretable machine learning. Nat Biotechnol. 2022, 40: 1520～1527.
41 An L, Said M, Tran L, et al. Binding and sensing diverse small molecules using shape-complementary pseudocycles. Science. 2024, 385: 276～282.
42 Bhardwaj G, Mulligan VK, Bahl CD, et al. Accurate de novo design of hyperstable constrained peptides. Nature. 2016, 538: 329～335.
43 Silva DA, Yu S, Ulge UY, et al. De novo design of potent and selective mimics of IL-2 and IL-15. Nature. 2019, 565: 186～191.
44 Ramesh A, Pavlov M, Goh G, et al. Zero-shot text-to-image generation. Proceedings of the 38th International Conference on Machine Learning[C]. 2021, 139: 8821～8831.
45 Guo Z, Liu J, Wang Y, et al. Diffusion models in bioinformatics and computational biology. Nat Rev Bioeng. 2024, 2: 136～154.
46 Watson JL, Juergens D, Bennett NR, et al. De novo design of protein structure and function with RFdiffusion. Nature. 2023, 620: 1089～1100.
47 Vazquez Torres S, Leung PJY, Venkatesh P, et al. De novo design of high-affinity binders of bioactive helical peptides. Nature. 2024, 626: 435～442.
48 Krishna R, Wang J, Ahern W, et al. Generalized biomolecular modeling and design with RoseTTAFold All-Atom. Science. 2024, 384: eadl2528.
49 Huang B, Xu Y, Hu X, et al. A backbone-centred energy function of neural networks for protein design. Nature. 2022, 602: 523～528.
50 Dauparas J, Anishchenko I, Bennett N, et al. Robust deep learning-based protein sequence design using ProteinMPNN. Science. 2022, 378: 49～56.
51 Dieckhaus H, Brocidiacono M, Randolph NZ, et al. Transfer learning to leverage larger datasets for improved prediction of protein stability changes. Proc Natl Acad Sci USA. 2024, 121: e2314853121.
52 Goverde CA, Pacesa M, Goldbach N, et al. Computational design of soluble and functional membrane protein analogues. Nature. 2024, 631: 449～458.
53 Goverde CA, Wolf B, Khakzad H, et al. De novo protein design by inversion of the AlphaFold structure prediction network. Protein Sci. 2023, 32: e4653.
54 Lee EF, Sadowsky JD, Smith BJ, et al. High-resolution structural characterization of a helical alpha/beta-peptide foldamer bound to the anti-apoptotic protein Bcl-xL. Angew Chem Int Ed Engl. 2009, 48: 4318～4322.