doi:10.3969/j.issn.2095-1736.2025.05.001

·特约综述·



叶盛,安徽大学人工智能学院教授,安徽省无人系统与智能技术工程研究中心副主任,安徽省通用人工智能领域战略咨询专家,中国科学院百篇优秀博士学位论文获得者。曾获得中国科学院院长奖特别奖、中国化学会京博科技奖优秀博士论文奖等荣誉奖励。聚焦人工智能与量子化学交叉领域,系统性地发展了结合量子化学与人工智能的蛋白质光谱模拟方法以及基于物理“谱-构-效”规则的蛋白质智能从头设计方法。近 5 年以第一作者或通信作者在国际知名期刊发表论文 20 余篇,多项研究工作被 *Science* 专文推荐点评。所开发的蛋白质光谱人工智能模拟软件目前已在中国科学技术大学、南京大学、南京南欣医药技术研究院有限公司、美国加州大学尔湾分校、英国诺丁汉大学、英国杜伦大学等单位应用。

人工智能驱动的蛋白质结构预测进展与应用前景

朱吕帅, 李志鹏, 刘欣悦, 叶 盛
(安徽大学 人工智能学院 安徽省无人系统与智能技术工程研究中心, 合肥 230601)

摘 要 蛋白质是生命活动的核心分子,其三维结构决定了其生物功能与作用机制。尽管 X 射线晶体学、核磁共振和冷冻电镜等实验方法在结构解析方面取得了丰硕成果,但仍面临成本高、耗时长和适用性受限的挑战。近年来,人工智能尤其是深度学习技术的飞速发展,为蛋白质结构预测带来了革命性突破。从早期的统计能量函数和同源建模,到融入注意力机制和大规模参数化网络的前沿深度学习模型,预测精度与速度均得到了显著提升。以 AlphaFold 和 RoseTTAFold 为代表的算法不仅在静态结构预测上屡创佳绩,还在变异体筛选、药物设计和精准医学等领域展现出广阔应用前景。此外,还系统阐述了基于蛋白质语言模型(如 ESM-3)的结构预测方法,同时进一步探讨了基于光谱描述符和基于大规模生物物理采样增强的深度学习这两类探索性动态结构预测策略,并评估了它们的研究进展与应用潜力,为未来研究提供理论与实践参考。

关键词 蛋白质结构预测; 人工智能; AlphaFold; RoseTTAFold; ESM-3; 光谱描述符
中图分类号 Q51 **文献标识码** A **文章编号** 2095-1736(2025)05-0001-09

Progress and prospects of AI-driven protein structure prediction

ZHU Lyushuai, LI Zhipeng, LIU Xinyue, YE Sheng
(Anhui Provincial Engineering Research Center for Unmanned Systems and Intelligent Technology, School of Artificial Intelligence, Anhui University, Hefei 230601, China)

Abstract Proteins are fundamental molecules central to life activity, with their three-dimensional structures determining their biological functions and mechanisms of action. Although experimental methods such as X-ray crystallography, nuclear magnetic resonance (NMR), and cryo-electron microscopy (cryo-EM) have achieved significant success in structural elucidation, they still face challenges such as high cost, long time consumption, and limited applicability. In recent years, rapid advancements in artificial intelligence, particularly deep learning techniques, have revolutionized protein structure prediction. From early statistical energy functions and homology modeling to cutting-edge deep learning models integrating multi-head attention mechanisms and large-scale parameterized networks, there have been substantial improvements in both prediction accuracy and efficiency. Algorithms represented by AlphaFold and RoseTTAFold have not only consistently achieved remarkable results in static structure prediction but also demonstrated broad application prospects in variant screening, drug design, and precision medicine. Furthermore, this review systematically presents structure-predic-

收稿日期:2025-04-10;**最后修回日期**:2025-07-22
基金项目:国家自然科学基金项目(22203001)
作者简介:朱吕帅,硕士研究生,研究方向为人工智能驱动的蛋白质与分子逆向设计和谱-构-效机制探索,E-mail:lushuaizhu722@gmail.com
通信作者:叶盛,教授,研究方向为人工智能驱动的蛋白质与分子逆向设计和谱-构-效机制探索,E-mail:yess@ahu.edu.cn

中国知网 https://www.cnki.net

tion methods based on protein language models (such as ESM-3), and further explores two categories of exploratory strategies−those based on spectral descriptors and those employing sampling-augmented deep learning with large-scale biophysical data−while assessing their research progress and application potential, thereby providing theoretical and practical guidance for future studies.

Keywords protein structure prediction; artificial intelligence; AlphaFold; RoseTTAFold; ESM-3; spectral descriptors

蛋白质是细胞功能的基本执行者,其三维结构不仅决定其生物学功能,还影响其在细胞内外的空间定位、稳定性以及与其他分子的特异性识别[1-2]。结构解析已成为理解生命活动分子机制与开发靶向干预策略的核心基础。例如,膜蛋白的跨膜结构与界面电荷分布直接决定其离子通道功能[3];阿尔茨海默病等神经退行性疾病的研究高度依赖于错折叠蛋白的聚集结构解析[4];而抗菌肽和小分子药物的设计则要求对其与靶标蛋白结合位点的空间构象有精准认知[5]。

长期以来,X 射线晶体衍射[6-7]、核磁共振(NMR)[8]和冷冻电镜(Cryo-EM)[9]等实验方法被视为蛋白质结构解析的“金标准”,为结构生物学提供了大量高分辨率数据[10]。然而,这些技术在实验周期、样品制备和适用范围方面存在显著限制,特别对动态、柔性或难结晶蛋白质,实验结构数据依然匮乏[11-12]。此外,实验方法获取的大多为静态结构,难以捕捉蛋白质在真实生理环境下的动态构象变化。在此背景下,计算结构预测方法作为重要补充逐步发展起来。尽管同源建模、分子动力学模拟和能量函数等传统方法在部分体系中取得一定进展,但总体受限于模板依赖性、计算复杂度和泛化能力,难以支撑对大规模未知蛋白结构的高效预测[13]。

近年来,深度学习的迅猛发展为蛋白质结构预测注入了全新动能[14-15]。以 AlphaFold2 为代表的人工智能模型,通过整合多序列比对、图神经网络与注意力机制,首次在无模板条件下实现接近实验精度的结构预测[16],标志着计算生物学进入“AI 结构解析”时代,该成果也荣获 2024 年诺贝尔化学奖[17]。此后,RoseTTAFold、ESMFold 和 OmegaFold 等多种结构预测模型相继问世,推动预测对象从单体蛋白扩展至蛋白质复合物、相互作用界面、变构动态路径等复杂生物体系[18-21]。与此同时,结构预测与多模态生物数据(如转录组、互作组与代谢组)的深度融合,正不断拓展蛋白质功能研究的系统性与时空维度[22-23]。

综上所述,AI 驱动的蛋白质结构预测正从“结构准确性”向“体系理解力”转变,成为连接序列信息、功能机制与生物调控网络的关键桥梁。本文将系统回顾该领域的技术演进与核心方法,比较主流 AI 模型的设计理念与适用场景,分析其在蛋白质结构解析与功能预测中的实际表现,探讨当前面临的挑战与限制,并展望其在动态构象、多尺度预测与功能耦合建模方面的未来发展方向。希望本综述为蛋白质结构生物学、人工智能、生物物理与计算生物等交叉研究提供系统参考与思路启发。

1 蛋白质结构人工智能预测方法的基本原理

为深入理解当前人工智能驱动蛋白质结构预测的技术支撑与机制基础,本文从核心原理层面出发,系统梳理主流模型的设计逻辑与建模策略,揭示其如何通过算法创新应对复杂构象建模中的关键挑战。

近年来,随着深度学习在结构生物学领域的迅猛发展,涌现出诸如 AlphaFold2、RoseTTAFold、ESMFold 和 OmegaFold 等具代表性的 AI 模型,它们在多个国际结构评估任务(如 CASP)中表现出远超传统方法的预测精度。其背后的核心在于这些模型普遍采用了一套融合进化共变信息编码、注意力机制、图神经网络建模与可微分几何精化的统一技术架构,该架构显著提升了整体预测准确性,在低同源性或缺乏模板的情境下依然具备稳健性能,突破了传统方法在远程相互作用建模与多尺度结构耦合方面的瓶颈[24-25]。

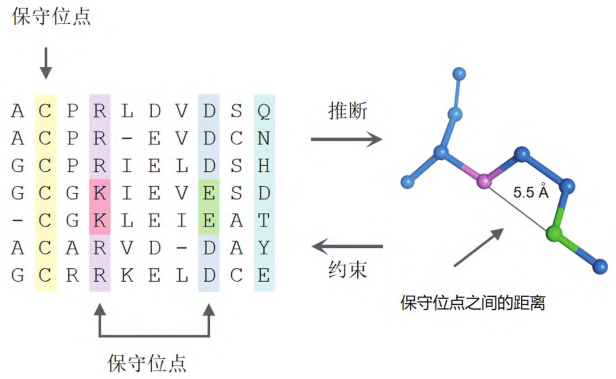
1.1 进化共变信息编码

进化共变信息编码是蛋白质结构预测中的关键技术之一,其核心思想是利用同源序列中的协同突变模式推断残基间的空间接触关系(图 1)。图 1 展示了如何从多序列比对(MSA)中识别保守位点,并将其用于蛋白质结构的推理与建模过程。在进化过程中,空间上相互作用的残基往往会出现共变,以维持蛋白质结构与功能的稳定性。通过 MSA 构建同源序列集合,并结合统计方法提取共变关系,可获得残基对之间的接触倾向,为结构预测提供高价值的输入特征。

主流模型通常将共变信息编码为高维特征张量,用于辅助构建残基接触图或距离矩阵。以 AlphaFold2 为代表,其采用联合建模策略,将 MSA 表示与残基对表示共同输入,并通过引入 Evoformer 模块实现跨维度的信息交互,显著提升了上下文依赖建模能力与信息利用效率。相比之下,传统 DCA 方法(如 GREMLIN、EVcouplings)更侧重于局部统计推断,难以捕捉复杂高阶关联[26-29]。

然而,当面向免疫蛋白、病毒蛋白或从头设计蛋白等同源序列稀缺的体系时,MSA 深度不足将严重限制共变信息的有效性。为此,近年来发展出不依赖 MSA 的结构预测模型,如 ESMFold 和 OmegaFold,它们利用蛋白质语言模型直接从单序列中学习潜在结构表达,为低同源序列提供了新的建模路径。

中国知网 https://www.cnki.net



通过对多条序列中保守残基的识别,可以建立结构推理所需的空间约束,如残基之间的距离。该过程结合序列保守性与结构几何信息,有助于引导模型生成具有生物学合理性的三维构象。

图 1 基于多序列比对(MSA)中保守位点的结构推理与几何约束施加示意图

Figure 1 Structure inference and geometric constraint guided by conserved positions from multiple sequence alignment (MSA)

1.2 注意力机制在远程约束建模中的应用

蛋白质结构中的远程残基相互作用(如 β 折叠链间氢键、长程盐桥和跨结构域接触)对其三维构象稳定性与功能形成具有决定性作用。然而,此类非局域关系跨越多个序列位置,难以被传统卷积或局部窗口方法有效捕捉。为解决这一关键挑战,近年来主流结构预测模型广泛引入注意力机制(transformer),实现了对任意残基对之间交互的全局建模能力[30]。

在此基础上,不同模型通过结构化设计进一步提升注意力机制在远程约束建模中的表现。AlphaFold2 采用循环堆叠的双通路架构,在 MSA 表示与残基对表示之间交替施加注意力,辅以三角更新和跳跃连接机制,使信息在不同表征间充分流动,从而强化长程依赖建模。而 RoseTTAFold 则通过统一框架将序列、几何约束与三维坐标联合编码,并在三分支神经网络中协同优化各表征,提升了结构构象迭代更新过程中的耦合效率与稳定性。

注意力机制的引入不仅显著提升了模型在复杂拓扑场景下的适应能力,尤其在 β 结构、跨结构域连接与拓扑嵌套等情境中展现出更强解析能力,也为多链复合物结构预测提供了关键的长程相互作用支持[31]。

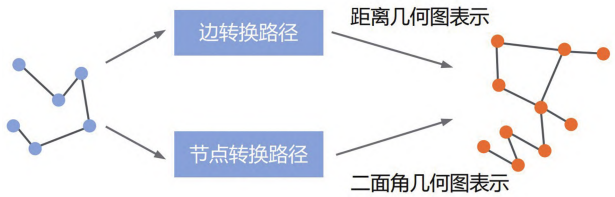
1.3 图神经网络对空间构象的精细建模

在蛋白质三维结构建模中,如何精确刻画残基间的空间构型与几何约束是实现高精度结构预测的核心环节。为此,研究者进一步从结构层面出发,将蛋白质抽象为由残基节点和几何边构成的图结构(图 2),从而引入图神经网络(GNN)作为关键建模工具,实现对结构信息的物理一致性建模。图 2 展示了如何将蛋白质结构信息映射为适用于图神经网络学习的几何图表示。

在此基础上,具备空间对称性约束的几何深度学习模型应运而生。代表性方法如 Graphformer、TFN(Tensor Field Networks)和 SE(3)-Transformer 等,通过结合节点特征(如氨基酸种类、主链构象)与边特征(如距离、接触类型),构建在旋转、平移等群对称性下保持不变的结构嵌入,有效提升了对三维几何关系的表达能力[32]。

AlphaFold2 中的结构模块通过引入图神经网络对残基距离图与扭转角图进行循环优化,实现了坐标预测的可微分重构,显著减少了传统优化中常见的“几何不一致”问题,如构象扭曲或非物理碰撞[33]。该机制不仅提高了模型的物理合理性,也增强了对局部几何细节的表达能力。

面向更具挑战性的多链体系建模任务,如蛋白质复合物、抗原-抗体复合物预测,图神经网络还可通过跨链图消息传递机制实现跨链相互作用建模。AlphaFold-Multimer 在结构图之间引入信息交互通道,使得多链结构之间的耦合关系得以有效捕捉,为抗体工程与免疫药物设计提供了强有力的结构解析工具。



边转换路径强调残基间的空间距离,节点转换路径体现局部构象的扭转角特征,有助于模型精准地对蛋白质的三维空间拓扑结构进行建模。

图 2 图神经网络中结构信息的双路径转换方式

Figure 2 Dual-path geometric encoding for protein structure in GNNs

1.4 可微分几何精化机制与结构收敛优化

在蛋白质结构预测的最后阶段,模型需将抽象的序列与图表示还原为物理合理、几何一致的三维坐标,这对预测精度与稳定性提出了更高要求。为此,现代结构预测模型在保持端到端可微框架的同时,引入了多项几何精化机制,确保最终构象具备物理可解释性与收敛性。

首先,以 AlphaFold2 为代表的模型引入了一种特殊的不变点注意力机制(invariant point attention, IPA),可在无需外部模板或参考结构的前提下,基于残基对的交互特征构建刚体框架并预测其空间位置。该机制在旋转与平移下保持不变性,显著提升了坐标输出的物理一致性与构象稳定性[16]。

在此基础上,AlphaFold2 进一步设计了循环回收(recycling)机制,即在初步预测的基础上多轮循环优化结构表征,实现三维构象的逐步修正与收敛。该过

中国知网 https://www.cnki.net

程不仅对局部几何参数如键长、键角、二面角进行精细调节,还结合了随机掩码预测与自蒸馏训练策略,显著提升了模型在低同源性、复杂拓扑和多结构域体系中的泛化能力与鲁棒性[34]。

相比之下,传统方法通常依赖 Rosetta Relax 或分子动力学(MD)模拟作为结构后处理步骤进行几何收敛,但其流程离散、误差易积累,难以实现与主模型的高效耦合。当前主流 AI 模型通过将几何建模、结构预测与精化过程整合为统一的可微分框架,实现了从序列到结构的端到端高精度预测,兼顾了速度、稳定性与物理合理性,为复杂蛋白体系的结构建模提供了坚实基础。

2 蛋白质结构人工智能预测方法的典型实现

2.1 AlphaFold 系列:从结构建模走向功能泛化的 AI 系统演进

AlphaFold 系列模型的迭代发展,不仅显著推动了蛋白质结构预测精度的极限,也深刻改变了人工智能在结构生物学中的应用范式。从最初的结构建模验证,到构建统一高精度框架,再到支持多组分体系的泛化建模,其三代演化轨迹充分体现了深度学习技术在生物复杂体系中的适应性与拓展性。

AlphaFold(初代)首次将蛋白质序列中的协变信息引入深度神经网络架构,通过残基对之间的距离和角度预测实现构象重建,在 CASP13 比赛中显著超越传统同源建模方法,尤其在无模板目标(如 T0998、T1000)上表现出色,验证了深度学习驱动结构预测的可行性[35]。尽管该模型仍依赖外部物理优化器完成最终坐标构建,且未能实现全原子预测,但它首次展示了深度协变分析在无模板情境下的结构学习潜力,为端到端结构预测系统的构建奠定了技术基础。

AlphaFold2 实现了从协变约束到坐标预测的架构飞跃。其核心架构包括 Evoformer 模块与结构模块(structure module),分别负责序列-结构联合建模与全原子坐标回归,构成了统一、端到端的结构预测流程。引入不变点注意力机制与结构置信度估计(pLDDT)以及循环回收(recycling)机制,使得模型在实验分辨率级别下输出高可信度结构[16]。AlphaFold2 广泛应用于人类蛋白质组解析,构建了超过 20 万条高精度结构模型,并在 GPCR、酶催化、抗原设计、致病突变筛查等任务中展现出卓越性能,成为结构生物学与生物医药研究中的基础平台。

AlphaFold3 在前代模型的基础上实现了功能维度的重大拓展,标志着 AI 结构预测从单体建模迈向多组分、生物功能导向的泛化阶段。该版本摒弃对多序列比对深度的依赖,创新性引入扩散模型对蛋白质-蛋白质、蛋白质-核酸与蛋白质-小分子复合物进行重构,并结合再训练与自监督机制提升复杂体系中的预测稳定性[36-38],其次,引入扩散模型(diffusion model)以替代传统的角度或刚体优化[图 3(d)]。扩散模型的基本思想是在训练过程中对分子结构进行随机扰动(前向扩散过程),再通过学习去除这些扰动(反向去噪过程),从而获得更为真实且合理的三维结构预测[39]。在 PoseBusters 等数据集上,AlphaFold3 在小分子结合位点、核酸识别界面、抗体结合片段建模方面超越传统对接算法[图 3(c)],成功预测了多类高复杂度体系(如病毒刺突蛋白-抗体复合体、转录因子-DNA-小分子复合体)[图 3(a)和(b)]。尽管其在分子动力学行为与 RNA 结构建模方面仍存在挑战[40-42],但整体性能的跃升已显著拓宽了 AI 在结构-功能耦合建模中的应用边界。

总体而言,AlphaFold 系列的三代演进构建了从序列驱动的结构学习到功能导向的系统建模的完整技术路径,为精准蛋白质结构解析、多分子相互作用预测与结构功能机制揭示提供了系统化、可推广的解决方案,推动蛋白质科学研究迈入智能化新阶段。

2.2 RoseTTAFold 系列模型:从多尺度建模到全组分精细预测

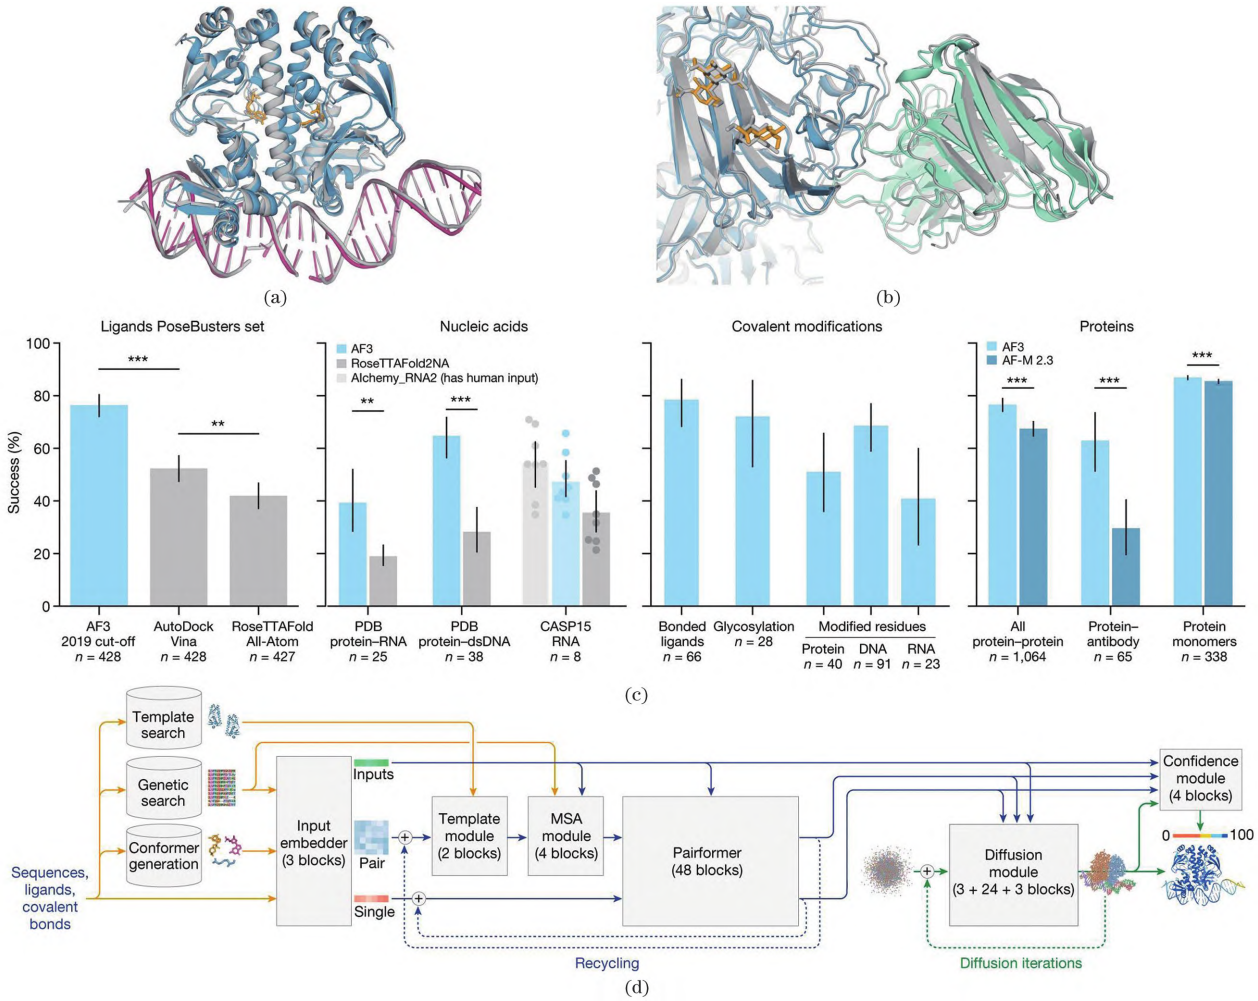
RoseTTAFold 作为继 AlphaFold 之后最具代表性的深度学习结构预测平台,开辟了另一条兼具工程可控性与体系适应性的技术路径。其核心创新在于将序列特征、残基对几何关系与三维坐标表示统一纳入网络架构中并行建模,通过多尺度协同学习实现对蛋白质结构的高效预测,并逐步扩展至原子级分辨率与多组分体系建模任务。

初代 RoseTTAFold 基于 trRosetta 的思想进行升级,提出了独特的三轨网络架构(3-track network),在序列(1D)、几何(2D)与结构(3D)等 3 条路径之间引入交叉注意力机制,允许信息在不同尺度间动态流动与融合[43]。该架构不仅能够直接输出粗略的 Cα 骨架,还可借助 Rosetta 物理引擎[44]完成全原子结构的构建。在 CASP14 比赛中,RoseTTAFold 取得平均 TM-score≈0.75,虽略低于 AlphaFold2,但在数据稀缺、任务复杂度中等的情境下展现出更强的灵活性与收敛效率,尤其在非结构域蛋白、蛋白质复合物和短肽系统中表现优异,成为兼具效率与准确性的“轻量级”建模方案。

为进一步提升原子级解析能力,RoseTTAFold All-Atom 在原始三轨架构基础上引入了两阶段结构预测策略[45]:第一阶段通过 backbone blocks 构建粗略骨架,第二阶段借助 3D 精化模块在坐标空间中细化侧链构

中国知网 https://www.cnki.net

象与非蛋白成分,实现真正意义上的端到端原子级预测[46]。该版本通过内嵌式 rotamer 预测与局部环境调优,替代了传统依赖 Rosetta 的外部优化流程,相比初代版本实现了约 1 Å 的全原子 RMSD 降低。



(a)细菌 CRP/FNR 家族转录因子与 DNA 及小分子 cGMP 复合物(PDB 7PZB);(b)人类冠状病毒 OC43 刺突蛋白(共 4 665 个残基,重度糖基化)与中和抗体的复合结构(PDB 7PNM);(c)AF3 在 PoseBusters、PDB 评估集和 CASP15 RNA 任务中的表现,包括配体对接、蛋白质-核酸界面、单体精度和抗体对接等指标(横坐标为任务类型,纵坐标为准确率/得分);***为 $P<0.001$;**为 $P<0.01$;(d)AlphaFold3 结构预测架构示意图。矩形表示处理模块,箭头表示数据流,黄色为输入数据,蓝色为网络内部激活值,绿色为输出结果,彩色球体表示原子坐标。

图 3 蛋白复合物与结构建模的深度学习方法[17]

Figure 3 Deep learning methods for protein complex and structural modeling[17]

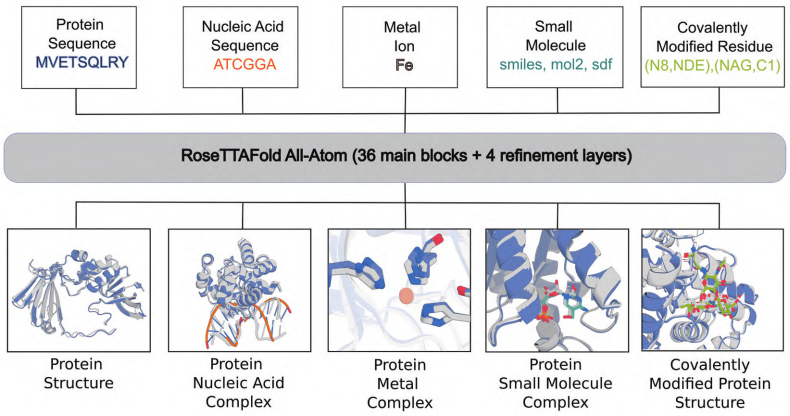
更具突破性的是,All-Atom 模型支持多种异质体系的直接输入,包括蛋白质-核酸、蛋白质-金属、蛋白质-小分子复合物及共价修饰蛋白等。RoseTTAFold All-Atom 的整体架构见图 4,无须显式预处理,大幅提升了建模流程的通用性与工程效率。该模型已成功应用于多个结构生物学任务中,如 CRISPR-Cas 蛋白质-核酸复合物解析、金属配位结构预测以及小分子结合位点构象建模,展现出在多分量生物体系中广泛的结构表达能力与实用价值。

RoseTTAFold 系列模型从多尺度协同学习出发,逐步走向全原子与全组分预测,为 AI 驱动下的结构生物学提供了可扩展、可泛化的解决方案,是继 AlphaFold 之后又一条极具潜力的深度学习建模路径。

2.3 ESM 系列模型:突破同源性瓶颈的蛋白质语言建模框架

在传统蛋白质结构预测方法普遍依赖多序列比对(MSA)以提取进化共变信息的背景下,ESM(evolutionary scale modeling)系列语言模型开辟了一条全新的建模路径。该系列模型摒弃 MSA 依赖,仅以蛋白质主序列为输入,通过大规模无监督学习挖掘序列中的演化规律与结构潜能,逐步构建出兼具结构预测与功能注释能力的通用表示学习框架。特别是 ESMFold 与 ESM-3 的相继提出,标志着语言模型驱动的蛋白质智能建模进入实用化与系统化新阶段。

中国知网 https://www.cnki.net



该模型通过主干结构预测模块与原子精度微调模块的协同工作，完成蛋白质及其配体、金属离子等多组分系统的全原子级结构建模。图中突出展示了侧链旋转异构体构象精细化、蛋白质-小分子复合物预测以及多种异质组分的建模能力，体现了其在复杂体系下的广泛适应性。

图 4 RoseTTAFold All-Atom 在蛋白复合物结构建模中的应用[45]

Figure 4 Applications of RoseTTAFold All-Atom in structural modeling of protein complex[45]

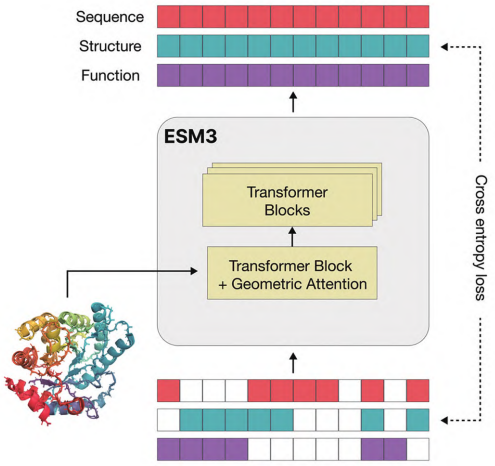
ESMFold 是首个完全摆脱 MSA 的端到端蛋白质结构预测模型，其核心创新在于将由预训练语言模型 ESM-2 所生成的高维序列嵌入作为唯一输入，结合简化版 Transformer 主干网络与 AlphaFold2 中的不变点注意力机制，实现对原子坐标的快速直接预测[47-48]。为弥补实验结构数据不足的问题，模型采用 AlphaFold2 生成结构作为蒸馏信号进行训练，从而有效提升了泛化能力。在 CAMEO 等基准测试中，ESMFold 取得平均 TM-score≈0.83，结构预测速度显著快于基于 MSA 的方法（快 6~60 倍）[47]，尤其适用于高通量筛选与未知序列快速注释任务。然而，由于缺乏对残基之间的互信息（mutual information, MI）显式建模，该模型在远程依赖建模和多组分体系预测方面仍存在一定局限。

为进一步突破这些限制，ESM-3 在 ESMFold 的基础上进行了结构性升级，构建了一个融合多任务、多尺度特征学习的统一平台。该模型引入几何注意力（geometric attention）机制与 Transformer-XL 架构，显著增强了对长序列中远程残基依赖关系的建模能力。图 5 展示了 ESM-3 基于堆叠的 Transformer 模块，融合了几何注意力来同时捕捉序列上下文与三维结构信息。通过三分支学习结构，同时优化序列重构、三维结构预测与功能注释等 3 个目标，形成结构与功能一体化学习机制[49]。ESM-3 引入循环注意力与相对位置编码，在提升建模深度的同时保持了计算效率，并整合 UniRef、MGnify、Swiss-Prot 等多个主流蛋白质序列数据库进行预训练，利用掩码语言建模任务充分挖掘序列中的上下文与演化信息[50-53]。

在实际应用中，ESM-3 在膜蛋白结构建模中表现尤为突出，F1-score 高达 0.89，较传统物理建模方法提升约 37%，同时在非结构域蛋白、多链复合物、功能位点预测等多任务场景中展现出广泛适用性。该模型的提出，不仅弥补了 MSA 依赖方法在低同源蛋白预测中的短板，也推动了蛋白质建模从“结构驱动”向“语言理解驱动”的范式转变，成为当前序列驱动结构与功能预测的代表性平台之一。

3 典型应用案例：从结构预测走向功能设计的实践探索

随着蛋白质结构人工智能模型的持续演进，其应用场景也正由传统的结构解析逐步拓展至抗体建模、酶工程优化与全新蛋白设计等功能导向任务。典型案例表明，AlphaFold、RoseTTAFold All-Atom 以及 ESM-3 等模型不仅在预测精度上达到了实验可用水平，更在多个重要生物任务中展现出对功能构象调控与全新序列生成的实用潜力。



模型在序列重构、结构预测与功能注释等 3 大任务上并行计算交叉熵损失，实现多任务共学，从而在多种蛋白质下游应用中展现出优异性能。

图 5 ESM-3 模型架构与多任务训练流程示意[49]

Figure 5 ESM-3 model architecture and multi-task training workflow[49]

中国知网 https://www.cnki.net

AlphaFold 在抗体–抗原复合物建模中的应用显示其在高通量、无需实验先验的抗体设计流程中的适配能力。Yin 等[54]通过构建 IgFold→HDOCK 与 IgFold→HER 两种管线,系统评估了 AlphaFold2 预测结构在抗原建模中的表现。结果表明,尽管与实验解析结构相比,AlphaFold2 所预测的抗原结构在界面构象上略有偏差(RMSD 略高、DockQ 略低),但其整体构象准确性(TM-score>0.67)和高 lDDT 指标仍支持其作为输入,用于大规模抗体–抗原复合体构建。特别是在缺乏后结合晶体结构的早期药物发现阶段,该方法可有效取代实验结构,推动抗体工程从结构筛选向结构设计的自动化演进。

RoseTTAFold All-Atom 在金属酶设计中的应用进一步展示了全原子级结构预测框架在功能优化任务中的精细调控能力。Ahern 等[55]将该模型与 RFdiffusion2 结合,设计锌离子参与的金属水解酶活性中心。通过 DFT 优化获得理想过渡态几何构象(theozyme)后,研究者利用 RoseTTAFold All-Atom 从头生成能够承载该活性位点的蛋白骨架,并自动优化主链构象与金属配位几何。结合 ProteinMPNN 进行序列优化和 Rosetta FastRelax 精细结构重构,仅在 96 个设计候选中便筛选出催化效率提升数百倍的高活性酶 ZETA_1,后续二轮筛选更获得进一步优化的 ZETA_2,充分验证了 AI 模型在精密酶设计中的高通量、高精度潜力。

ESM-3 在绿色荧光蛋白(GFP)设计中的应用则展示了语言模型驱动下的生成式蛋白质设计范式。Hayes 等[49]利用 ESM-3 构建一个跨越自然进化空间的生成模型,在不依赖结构模板与多序列比对的前提下,模拟超过 5 亿年的蛋白演化过程,成功生成与天然 GFP 序列仅 58% 同源的全新荧光蛋白 esmGFP。该蛋白经实验合成、体外表达与光谱测试,展现出与天然 GFP 相当的激发/发射特性与亮度,验证其功能可用性。进化分析进一步指出,esmGFP 所在的序列空间若通过自然突变需超过 5 亿年才能达成,显示出 ESM-3 在探索“超自然”蛋白设计空间中的独特优势。

综上,这些案例清晰展现了当前蛋白质结构 AI 模型正从“结构预测工具”加速迈向“功能设计平台”的转变。它们不仅支持从头构建结构合理的新蛋白,更能高效引导功能优化与实验验证,推动生物设计范式由经验驱动向数据智能驱动转型,为药物研发、酶工程、蛋白材料等前沿领域提供了全新支撑路径(表 1)。

表 1 3 种蛋白质结构预测方法性能对比

Table 1 Performance comparison of three protein structure prediction methods

方法 Method	预测精度 Prediction accuracy	推理速度 Inference speed	可扩展性 Scalability
AlphaFold3	极高:单体 GDT_TS ≈ 0.92,复合物 RMSD≈1.2 Å	中等:单体/复合体均约 40 min	中等:支持多链复合物,受限于 MSA
RoseTTAFold All-Atom	高:骨架 TM-score≈0.75,全原子 RMSD≈2.5 Å	较快:单链数分钟	较好:原子级复合物端到端预测
ESM-3	中高:长链蛋白 RMSD 改善 15%,F1≈0.89	极快:单序列数秒	极佳:超长序列与多任务兼容

注:对 AlphaFold3、RoseTTAFold All-Atom、ESM-3 方法在预测精度、推理速度和可扩展性进行了对比,其中,推理速度测试基准为单卡 A800 80G。

4 蛋白质动态结构预测:从路径建模到光谱反演的智能演进

随着 AlphaFold 等模型在静态结构预测领域取得突破性进展,蛋白质结构生物学的研究焦点正逐步从静态构象拓展至动态过程。现实生理环境中,蛋白质分子常处于不断变构与功能切换状态,其瞬时构象变化往往决定其识别、催化与调控能力。因此,如何准确解析蛋白质在时间尺度上的结构演化路径,揭示构象变化与理化性质之间的耦合机制,进而构建具备时空分辨率的结构–功能关联模型,已成为当前结构生物学面临的核心科学挑战。

为应对这一挑战,研究者发展出一系列融合深度学习与生物物理模拟的方法。其中,PATHpre 模型代表了基于大规模构象采样的动态结构预测范式[56]。该方法首先利用增强采样策略(如 Metadynamics、Umbrella Sampling)生成连接已知端点结构的数千条过渡路径,并将其转化为残基–残基距离矩阵序列,构建高能态轨迹库。在此基础上,HESpre 模块采用残差卷积神经网络(ResNet)对端点结构及初步路径片段进行建模,初步预测构象变化中的关键中间态。随后,PATHpre 引入图神经网络与注意力机制,对高能中间态的距离矩阵进行迭代优化,每一步生成新的约束条件,结合短时约束分子动力学(皮秒级)快速重建三维坐标。整个流程形成从起始构象到中间态构建再到空间重构的闭环端到端系统,无须人工设定反应坐标,显著提升了对复杂构象转换路径的泛化与效率,实验证明其在数分钟内即可重现生物大分子的关键动态过程,且精度超越传统长程分子动力学方法。

红外光谱作为典型的分子光谱技术,通过分析酰胺Ⅰ区等特征振动信号,能够非破坏性地揭示蛋白质

中国知网 https://www.cnki.net

的二级结构组成及其构象变化[57],为动态结构研究提供了可靠的实验观测基础[58-62]。在此基础上,近年来又涌现出融合分子光谱信息的人工智能动态建模方法,实现了从实验观测信号到三维动态结构的直接预测。以 Ye 等[63]提出的光谱驱动方法为代表,研究者发展了一种基于 DeepLabV3 网络的谱-构映射机制。该模型通过机器学习自动提取二维红外光谱(2DIR)中的时序特征,并预测对应的蛋白质瞬时三维结构,平均 Cα RMSD 误差低至 2.54 Å。整个流程包括“数据集构建-模型训练-结构预测”3 个阶段,形成由光谱信号驱动的结构生成闭环。不仅在静态结构预测中与实验数据高度一致,更重要的是,该方法能够在微秒至毫秒的时间尺度上高效捕捉蛋白质构象的演化趋势,其预测结果与分子动力学模拟轨迹显著吻合,为蛋白质动态过程的实时解析提供了光谱-智能融合的新路径。

综上所述,从基于采样轨迹的路径预测模型到基于光谱描述符的直接结构反演,蛋白质动态结构预测正逐步从物理驱动走向实验信号驱动与人工智能耦合的融合阶段,不仅拓展了传统结构预测的时间维度,也为功能调控、药物筛选与蛋白质工程提供了全新的理论工具与技术手段。

5 总结与展望

综上所述,蛋白质结构预测领域近年来取得了显著进展,尤其是人工智能技术的深入应用与跨学科融合极大地推动了蛋白质静态与动态结构预测精度与效率的提升。AlphaFold3、RoseTTAFold All-Atom 和 ESM-3 等模型,通过结合深度学习、注意力机制与图神经网络等创新模型架构,突破了传统计算方法的局限性,实现了对蛋白质结构预测的精准化、自动化和多维化。这些模型不仅在单链蛋白、蛋白复合物与蛋白质-配体体系的结构预测中展现出强大的预测能力,也在抗体设计、多功能酶工程和蛋白质-蛋白质界面设计等领域取得了显著成果。

此外,以 PATHpre 为代表的新兴模型利用增强采样分子动力学与残差卷积网络,快速精准地预测蛋白质构象转变过程中的关键中间态结构,并通过注意力机制与图神经网络进行迭代优化,结合短时分子动力学模拟实现动态结构重建。与此同时,结合二维红外光谱与 DeepLabV3 深度学习算法的新方法,实现了从光谱信号到三维结构的高效映射,捕捉微秒至毫秒尺度蛋白质动态变化,其预测精度与经典分子动力学结果高度一致。这些探索性方法为动态结构预测提供了创新的技术路线,进一步拓展了蛋白质结构研究的理论与应用边界。

未来的研究方向应继续致力于提高现有模型在复杂生物体系与多尺度动态过程中的泛化性能,尤其需解决模型在处理大规模蛋白质复合物、膜蛋白与非经典蛋白体系等方面的挑战。此外,还需增强模型与 cryo-EM、NMR、质谱等实验技术的协同应用能力,并建立更为标准化的数据集与性能评估体系。同时,在计算资源的高效分配与算法优化方面进行深入探索,以降低计算成本,推动蛋白质结构预测方法在科研与产业中的广泛应用。这些持续的技术创新与理论突破,将为生命科学基础研究提供强有力的理论支撑,并在精准医学、药物设计、合成生物学和生物技术产业中发挥日益重要的作用,促进相关领域的快速发展与创新。

参考文献

[1] ANFINSEN C B. Principles that govern the folding of protein chains [J]. Science, 1973, 181(4096): 223-230.
[2] GOODSELL D S, OLSON A J. Structural symmetry and protein function[J]. Annual Review of Biophysics and Biomolecular Structure, 2000, 29: 105-153.
[3] KRATOCHVIL H T, CARR J K, MATULEF K, et al. Instantaneous ion configurations in the K^+ ion channel selectivity filter revealed by 2D IR spectroscopy[J]. Science, 2016, 353(6303): 1040-1044.
[4] QIANG W, YAU W M, LU J X, et al. Structural variation in amyloid-β fibrils from Alzheimer' s disease clinical subtypes[J]. Nature, 2017, 541(7636): 217-221.
[5] FJELL C D, HISS J A, HANCOCK R E W, et al. Designing antimicrobial peptides: form follows function[J]. Nature Reviews Drug Discovery, 2011, 11(1): 37-51.
[6] CHAPMAN H N, FROMME P, BARTY A, et al. Femtosecond X-ray protein nanocrystallography[J]. Nature, 2011, 470(7332): 73-77.
[7] SHI Y. A glimpse of structural biology through X-ray crystallography [J]. Cell, 2014, 159(5): 995-1014.
[8] GIUNTA C J, MAINZ V V. Discovery of nuclear magnetic resonance: Rabi, Purcell, and Bloch[M]//Pioneers of Magnetic Resonance. Washington, DC: American Chemical Society, 2020: 3-20.
[9] XU B, LIU L. Developments, applications, and prospects of cryo-electron microscopy[J]. Protein Science, 2020, 29(4): 872-882.
[10] WUYUN Q, CHEN Y, SHEN Y, et al. Recent progress of protein tertiary structure prediction[J]. Molecules, 2024, 29(4): 832.
[11] LINDORFF-LARSEN K, PIANA S, DROR R O, et al. How fast-folding proteins fold[J]. Science, 2011, 334(6055): 517-520.
[12] MOSALAGANTI S, OBARSKA-KOSINSKA A, SIGGEL M, et al. AI-based structure prediction empowers integrative structural analysis of human nuclear pores[J]. Science, 2022, 376(6598): eabm9506.
[13] LANE T J. Protein structure prediction has reached the single-structure frontier[J]. Nature Methods, 2023, 20(2): 170-173.
[14] BJÖRCK J, GOMES C, SELMAN B, et al. Understanding batch normalization [C]//Proceedings of the 32nd International Conference on Neural Information Processing Systems (NIPS' 18). Red Hook, NY: Curran Associates Inc., 2018: 7705-7716.
[15] SHAFIQ M, GU Z. Deep residual learning for image recognition: a survey[J]. Applied Sciences, 2022, 12(18): 8972.
[16] JUMPER J, EVANS R, PRITZEL A, et al. Highly accurate protein structure prediction with AlphaFold[J]. Nature, 2021, 596(7873): 583-589.
[17] ABRAMSON J, ADLER J, DUNGER J, et al. Addendum: accurate structure prediction of biomolecular interactions with AlphaFold3[J]. Nature, 2024, 636(8042): E4.
[18] STÄRK H, GANEA O, PATTANAIK L, et al. EquiBind: geometric deep learning for drug binding structure prediction[C]//Proceedings of the 39th International Conference on Machine Learning (ICML' 22). Baltimore, MD, USA: PMLR, 2022: 20503-20521.
[19] GUO Z, LIU J, SKOLNICK J, et al. Prediction of inter-chain distance maps of protein complexes with 2D attention-based deep neu-

中国知网 https://www.cnki.net

ral networks[J]. Nature Communications, 2022, 13(1): 6963.
[20] JIANG D, HSIEH C Y, WU Z, et al. InteractionGraphNet: a novel and efficient deep graph representation learning framework for accurate protein-ligand interaction predictions[J]. Journal of Medicinal Chemistry, 2021, 64(24): 18209-18232.
[21] QIAO Z, NIE W, VAHDAT A, et al. State-specific protein-ligand complex structure prediction with a multiscale deep generative model[J]. Nature Machine Intelligence, 2024, 6: 195-208.
[22] JIANG H, WANG J, CONG W, et al. Predicting protein-ligand docking structure with graph neural network[J]. Journal of Chemical Information and Modeling, 2022, 62(12): 2923-2932.
[23] LIN P C, LI H, HUANG S Y. Deep learning in modeling protein complex structures: from contact prediction to end-to-end approaches[J]. Current Opinion in Structural Biology, 2024, 85: 102789.
[24] DAUPARAS J, ANISHCHENKO I, BENNETT N, et al. Robust deep learning-based protein sequence design using ProteinMPNN[J]. Science, 2022, 378(6615): 49-56.
[25] XIA Y, ZHAO K, LIU D, et al. Multi-domain and complex protein structure prediction using inter-domain interactions from deep learning[J]. Communications Biology, 2023, 6(1): 1221.
[26] NUTE M, SALEH E, WARNOW T. Evaluating statistical multiple sequence alignment in comparison to other alignment methods on protein data sets[J]. Systematic Biology, 2019, 68(3): 396-411.
[27] ZHANG C, WANG Q, LI Y, et al. The historical evolution and significance of multiple sequence alignment in molecular structure and function prediction[J]. Biomolecules, 2024, 14(12): 1531.
[28] COCCO S, MONASSON R, WEIGT M. From principal component to direct coupling analysis of coevolution in proteins: low-eigenvalue modes are needed for structure prediction[J]. PLoS Computational Biology, 2013, 9(8): e1003176.
[29] MORCOS F, HWA T, ONUCHIC J N, et al. Direct coupling analysis for protein contact prediction[J]. Methods in Molecular Biology, 2014, 1137: 55-70.
[30] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need [C]//Proceedings of the 31st International Conference on Neural Information Processing Systems (NeurIPS' 17). Red Hook, NY: Curran Associates Inc., 2017: 6000-6010.
[31] CAREDDA F, PAGNANI A. Direct coupling analysis and the attention mechanism[J]. BMC Bioinformatics, 2025, 26(1): 41.
[32] SCARSELLI F, GORI M, TSOI A C, et al. The graph neural network model[J]. IEEE Transactions on Neural Networks, 2009, 20(1): 61-80.
[33] ZHANG O, WANG T, WENG G, et al. Learning on topological surface and geometric structure for 3D molecular generation[J]. Nature Computational Science, 2023, 3(10): 849-859.
[34] XU T, XU Q, LI J. Toward the appropriate interpretation of AlphaFold2[J]. Frontiers in Artificial Intelligence, 2023, 6: 1149748.
[35] SENIOR A W, EVANS R, JUMPER J, et al. Improved protein structure prediction using potentials from deep learning[J]. Nature, 2020, 577(7792): 706-710.
[36] VARADI M, ANYANGO S, DESHPANDE M, et al. AlphaFold Protein Structure Database: massively expanding the structural coverage of protein-sequence space with high-accuracy models[J]. Nucleic Acids Research, 2022, 50(D1): D439-D444.
[37] MELNYK I, LOZANO A, DAS P, et al. AlphaFold distillation for inverse protein design[J]. Scientific Reports, 2025, 15(1): 21743.
[38] SKOLNICK J, GAO M, ZHOU H, et al. AlphaFold 2: why it works and its implications for understanding the relationships of protein sequence, structure, and function[J]. Journal of Chemical Information and Modeling, 2021, 61(10): 4827-4831.
[39] YIM J, STÄRK H, CORSO G, et al. Diffusion models in protein structure and docking[J]. WIREs Computational Molecular Science, 2024, 14(2): e1711.
[40] MCDONNELL R T, HENDERSON A N, ELCOCK A H. Structure prediction of large RNAs with AlphaFold3 highlights its capabilities and limitations[J]. Journal of Molecular Biology, 2024, 436(22): 168816.
[41] JI Z, LEE N, FRIESKE R, et al. Survey of hallucination in natural language generation[J]. ACM Computing Surveys, 2023, 55(12): 1-38.
[42] DESAI D, KANTLIWALA S V, VYBHAVI J, et al. Review of AlphaFold 3: transformative advances in drug design and therapeutics [J]. Cureus, 2024, 16(7): e63646.
[43] BAEK M, DIMAIO F, ANISHCHENKO I, et al. Accurate prediction of protein structures and interactions using a three-track neural network[J]. Science, 2021, 373(6557): 871-876.
[44] YANG J, ANISHCHENKO I, PARK H, et al. Improved protein structure prediction using predicted interresidue orientations[J]. Proceedings of the National Academy of Sciences of the United States of America, 2020, 117(3): 1496-1503.
[45] KRISHNA R, WANG J, AHERN W, et al. Generalized biomolecular modeling and design with RoseTTAFold all-atom[J]. Science, 2024, 384(6693): eadl2528.
[46] ALFORD R F, LEAVER-FAY A, JELIAZKOV J R, et al. The Rosetta all-atom energy function for macromolecular modeling and design[J]. Journal of Chemical Theory and Computation, 2017, 13 (6): 3031-3048.
[47] LIN Z, AKIN H, RAO R, et al. Evolutionary-scale prediction of atomic-level protein structure with a language model[J]. Science, 2023, 379(6637): 1123-1130.
[48] RIVES A, MEIER J, SERCU T, et al. Biological structure and function emerge from scaling unsupervised learning to 250 million protein sequences[J]. Proceedings of the National Academy of Sciences of the United States of America, 2021, 118(15): e2016239118.
[49] HAYES T, RAO R, AKIN H, et al. Simulating 500 million years of evolution with a language model[J]. Science, 2025, 387(6736): 850-858.
[50] BURLEY S K, BERMAN H M, BHIKADIYA C, et al. RCSB Protein Data Bank: biological macromolecular structures enabling research and education in fundamental biology, biomedicine, biotechnology and energy[J]. Nucleic Acids Research, 2019, 47(D1): D464-D474.
[51] HAAS J, BARBATO A, BEHRINGER D, et al. Continuous Automated Model EvaluatiOn (CAMEO) complementing the critical assessment of structure prediction in CASP12[J]. Proteins: Structure, Function, and Bioinformatics, 2017, 86: 387-398.
[52] KRYSHTAFOVYCH A, SCHWEDE T, TOPF M, et al. Critical assessment of methods of protein structure prediction (CASP)-Round XIV[J]. Proteins, 2021, 89(12): 1607-1617.
[53] MITCHELL A L, ALMEIDA A, BERACOCHEA M, et al. MGnify: the microbiome analysis resource in 2020[J]. Nucleic Acids Research, 2020, 48(D1): D570-D578.
[54] YIN R, PIERCE B G. Evaluation of AlphaFold antibody-antigen modeling with implications for improving predictive accuracy[J]. Protein Science, 2024, 33(1): e4865.
[55] AHERN W, YIM J, TISCHER D, et al. Atom level enzyme active site scaffolding using RFdiffusion2[J]. bioRxiv, 2025, doi: 10.1101/2025.04.09.648075.
[56] HU Y, YANG H, LI M, et al. Exploring protein conformational changes using a large-scale biophysical sampling augmented deep learning strategy[J]. Advanced Science, 2024, 11(44): e2400884.
[57] PUPEZA I, HUBER M, TRUBETSKOV M, et al. Field-resolved infrared spectroscopy of biological systems[J]. Nature, 2020, 577 (7788): 52-59.
[58] BAIZ C R, BŁASIAK B, BREDENBECK J, et al. Vibrational spectroscopic map, vibrational spectroscopy, and intermolecular interaction[J]. Chemical Reviews, 2020, 120(15): 7152-7218.
[59] BARTH A. Infrared spectroscopy of proteins[J]. Biochimica et Biophysica Acta (BBA) - Bioenergetics, 2007, 1767(9): 1073-1101.
[60] JANSEN T L C, KNOESTER J. Waiting time dynamics in two-dimensional infrared spectroscopy[J]. Accounts of Chemical Research, 2009, 42(9): 1405-1411.
[61] MUKAMEL S, ABRAMAVICIUS D, YANG L, et al. Coherent multidimensional optical probes for electron correlations and exciton dynamics: from NMR to X-rays[J]. Accounts of Chemical Research, 2009, 42(4): 553-562.
[62] LORENZ-FONFRIA V A. Infrared difference spectroscopy of proteins: from bands to bonds[J]. Chemical Reviews, 2020, 120(7): 3466-3576.
[63] YE S, ZHU L, ZHAO Z, et al. AI protocol for retrieving protein dynamic structures from two-dimensional infrared spectra[J]. Proceedings of the National Academy of Sciences of the United States of America, 2025, 122(7): e2424078122.

中国知网 https://www.cnki.net